

Документация по очистке данных

Before VS After

1. Сравнение датасета: До и После очистки

Характеристика	До очистки (anime_catalog.csv)	После очистки (anime_catalog_clean.csv)
Количество строк	10 142 [cite: 1]	10 142 [cite: 1]
Количество столбцов	26 [cite: 1]	16 [cite: 1]
Пропущенные значения	Присутствуют (в 10 столбцах более 20% пропусков) [cite: 1]	Отсутствуют (все пропуски обработаны) [cite: 1]
Формат года (year)	Строковый (с текстом, напр. "Весна 1983") [cite: 1]	Целочисленный (напр. 1983) [cite: 1]
Формат просмотров (site_views)	Строковый (напр. "27 311 просмотров") [cite: 1]	Целочисленный (напр. 27311) [cite: 1]
Списки (жанры, студии и др.)	Слитная строка с разделителем " " [cite: 1]	Структурированные списки (Python lists) [cite: 1]

2. Описание шагов предобработки (Preprocessing Steps)

1. Анализ и удаление неинформативных столбцов:

В ходе первичного осмотра было выявлено 10 столбцов, в которых отсутствовало более 20% данных [cite: 1]. Из них 8 столбцов имели 100% пропусков (например, shikimori_rating, mal_rating) и были полностью удалены из датасета [cite: 1]. Столбцы kinopoisk_rating и kinopoisk_url также были удалены из-за большого количества пропусков и низкой релевантности для дальнейшего анализа [cite: 1].

2. Обработка пропущенных значений (Imputation):

- В столбце `alt_names` (альтернативные названия) единичные пропуски были заменены на пустые строки [cite: 1].
- Пропуски в категориальных текстовых признаках `genres`, `director`, `dubbing` и `studio` были заполнены заглушкой *'Unknown'* для сохранения структуры данных [cite: 1].
- В столбце `year` (год выпуска) был применен метод извлечения 4-значного числа из текста [cite: 1]. Оставшиеся пропуски (где год не был указан изначально) были заполнены медианным значением года по всему датасету, после чего тип данных был приведен к целочисленному (`int`) [cite: 1].

3. Преобразование типов данных:

Из столбца `site_views` (количество просмотров) с помощью регулярных выражений были извлечены только цифровые значения, а текстовый мусор удален [cite: 1]. Очищенные значения конвертированы в числовой формат `int` для возможности проведения количественного анализа [cite: 1].

4. Форматирование строковых массивов:

Значения в столбцах `genres`, `alt_names`, `studio`, `director` и `dubbing`, изначально записанные как слитный текст с разделителем `|`, были программно разделены [cite: 1]. Теперь эти ячейки содержат полноценные списки, что существенно упрощает фильтрацию и агрегацию данных [cite: 1].